UNIVERSIDAD DE CALDAS

Bases de datos relacionales

Entrega 1. Proyecto Final: Diseño y Configuración del Sistema Híbrido Relacional-Vectorial para RAG

Campo	Información del grupo
Nombre del proyecto	Sistema de Gestión de Información de Laboratorio (LIMS) Híbrido con Búsqueda Multimodal y RAG
Dominio de datos	Gestión operativa de laboratorios científicos, control de inventario químico, trazabilidad experimental y análisis asistido por IA
Modalidad	Terna
Entidades mínimas exigidas	15 (Modalidad Terna)
Entidades en el ERD entregado	21 entidades (15 del dominio de laboratorio + 5 adicionales del núcleo RAG y tablas vectoriales)
Integrante 1	Estupiñán
Integrante 2	Noreña
Integrante 3	Puerta
Repositorio Git	https://github.com/Futbol2007/Gestion-laboratorio-con-RAG
Fecha de entrega	14 de octubre de 2026

1. UNIVERSO DEL DISCURSO Y ANÁLISIS DE REQUERIMIENTOS

1.1 Descripción del dominio

El sistema modela la operación integral de un centro de investigación y análisis científico mediante un Sistema de Gestión de Información de Laboratorio (LIMS). En la operación diaria, los investigadores adscritos a distintos departamentos ejecutan experimentos asociados a proyectos de investigación formales, siguiendo protocolos operativos estandarizados (SOPs), controlando las condiciones ambientales del recinto (temperatura, humedad y presión), consumiendo lotes específicos de reactivos químicos con control de caducidad y peligrosidad, utilizando equipamiento científico sujeto a bitácoras de uso y mantenimiento, y generando tanto muestras biológicas o químicas como residuos regulados.

El módulo de Generación Aumentada por Recuperación (RAG) y búsqueda vectorial resuelve la fragmentación crítica entre los datos transaccionales del laboratorio y el conocimiento científico no estructurado. Permite a los investigadores, analistas y técnicos consultar en lenguaje natural manuales de procedimientos, hojas de seguridad y guías metodológicas (`Protocolo_Estandar` / `Documento`), así como recuperar fotografías microscópicas, cromatografías o espectrogramas asociados a las muestras y protocolos (`Imagenes`) a partir de descripciones morfológicas en texto libre, combinando la similitud semántica en alta dimensionalidad con filtros relacionales exactos sobre el inventario químico, condiciones climáticas e historial de métricas analíticas (`Resultado_Estructurado`).

1.2 Actores y fuentes de datos

Actor / fuente	Descripción	Volumen estimado
Usuario Investigador / Analista (`Investigador`)	Lidera proyectos, ejecuta experimentos en el laboratorio, registra muestras y métricas tabulares, y consulta en lenguaje natural el sistema híbrido RAG buscando protocolos y evidencia visual microscópica con rol de `investigador` o `analista`.	50 – 150 usuarios activos
Técnico de Equipos y Calidad	Audita el uso de maquinaria científica, registra mantenimientos preventivos/correctivos, supervisa el inventario de lotes de reactivos y controla el descarte seguro de desechos con rol `tecnico`.	15 – 30 usuarios
Fuente de documentos (`Protocolo_Estandar`)	Manuales operativos estándar (SOPs), guías metodológicas de laboratorio y hojas de datos de seguridad (MSDS) en español (`es`) e inglés (`en`), provenientes de repositorios académicos e internos en formatos PDF, Markdown y texto plano.	500 – 2.000 documentos técnicos
Fuente de imágenes (`Imagenes`)	Capturas de microscopía óptica y electrónica, tinciones celulares, precipitados químicos y espectros obtenidos de las muestras experimentales o incluidos como figuras técnicas en los protocolos (formatos PNG y JPG, licencia abierta / académica interna).	2.000 – 10.000 imágenes

1.3 Requerimientos funcionales

ID	Requerimiento	Tipo de consulta que lo satisface
RF-01	Buscar y filtrar protocolos estándar, experimentos ejecutados y lotes de reactivos por idioma (`es`/`en`), rango de fechas de ejecución, nivel de peligrosidad química (1 a 5) o fecha de caducidad.	SQL clásica
RF-02	Encontrar fragmentos (*chunks*) de protocolos estándar (`Protocolo_Estandar`) semánticamente similares a una pregunta metodológica o anomalía experimental formulada en lenguaje natural por el investigador.	Vectorial texto-texto

ID	Requerimiento	Tipo de consulta que lo satisface
RF-03	Encontrar fotografías microscópicas o figuras técnicas de muestras (**`Imagenes`**) a partir de una descripción morfológica o visual en texto libre (ej. *"precipitado cristalino con coloración violácea en medio ácido"*).	Vectorial texto-imagen
RF-04	Combinar filtros relacionales de metadatos (ej. experimentos realizados a temperatura mayor a 25 °C en **`Condicion_Ambiental`** o que consumieron un reactivo con **`nivel_peligro >= 4`**) con búsqueda de similitud semántica sobre protocolos e imágenes.	Híbrida (SQL + Vectorial)
RF-05	Generar una respuesta técnica explicativa para el investigador integrando como contexto los pasos recuperados del protocolo estándar y las mediciones de **`Resultado_Estructurado`** asociadas.	RAG
RF-06	Registrar y consultar métricas de calidad por consulta (**`faithfulness`**, **`answer_relevancy`**, **`context_recall`** en **`Evaluaciones`**), así como reportes agregados de consumo de reactivos y uso de equipos por departamento.	SQL analítica
RF-07	Auditar la trazabilidad completa de un experimento: investigador ejecutor, proyecto asociado, protocolo aplicado, lotes de reactivos consumidos, muestras recolectadas y desechos generados.	SQL clásica (Joins múltiples)

1.4 Supuestos y restricciones del dominio

- Un departamento agrupa a múltiples investigadores, pero cada investigador pertenece formalmente a un único departamento (1:N).
- Un investigador principal puede liderar múltiples proyectos de investigación, y cada proyecto agrupa múltiples experimentos a lo largo del tiempo (1:N).
- Cada experimento es ejecutado por un único investigador responsable, pertenece a un único proyecto y se rige por un único protocolo estándar (**`Protocolo_Estandar`**).
- Las condiciones ambientales (temperatura, humedad y presión) se registran de manera única por cada experimento ejecutado (relación 1:1 garantizada mediante restricción **`UNIQUE`** sobre **`id_experimento`** en **`Condicion_Ambiental`**).
- Un compuesto químico del catálogo (**`Reactivo`**) puede tener múltiples envases físicos en inventario (**`Lote_Reactivo`**), y un experimento puede consumir fracciones de varios lotes a través de la tabla intermedia **`Consumo_Lote_Reactivo`** (N:M).
- De un experimento se obtienen múltiples muestras físicas (**`Muestra`**), y una misma muestra arroja múltiples mediciones numéricas tabulares en **`Resultado_Estructurado`** (1:N).
- Una imagen (**`Imagenes`**) pertenece obligatoriamente a un protocolo/documento de referencia (**`Protocolo_Estandar`**) y opcionalmente captura la evidencia visual de una **`Muestra`** experimental.
- Cada consulta formulada al sistema (**`Consultas`**) es realizada por un investigador, recupera uno o varios documentos o imágenes registrados en **`Resultados`** y posee una única evaluación consolidada en **`Evaluaciones`** (1:1).

2. DISEÑO CONCEPTUAL

2.1 Catálogo de entidades

El diseño conceptual unifica las 6 entidades obligatorias del núcleo RAG (donde **`Investigador`** actúa como **`Usuario`** y **`Protocolo_Estandar`** actúa como **`Documento`**) con las entidades propias del dominio de laboratorio (LIMS) y las tablas vectoriales:

#	Entidad	Tipo (núcleo / dominio / vectorial / intermedia)	Descripción breve	Atributo identificador
1	**Usuario (`Investigador`)**	Núcleo / Dominio	Científico, analista o técnico del laboratorio que ejecuta experimentos y realiza consultas al sistema RAG.	**`id_investigador`**
2	**Documento (`Protocolo_Estandar`)**	Núcleo / Dominio	Manual operativo estándar (SOP) o guía metodológica que rige los experimentos y se fragmenta en *chunks*.	**`id_protocolo`**
3	**Imagen (`Imagenes`)**	Núcleo	Fotografía microscópica, espectro o figura técnica asociada a un protocolo y opcionalmente a una muestra física.	**`id_img`**
4	**Consulta (`Consultas`)**	Núcleo	Pregunta en lenguaje natural formulada por un investigador al motor de búsqueda híbrido/RAG.	**`id_consulta`**
5	**Resultado (`Resultados`)**	Núcleo / Intermedia	Registro de recuperación que vincula una consulta con el protocolo o imagen hallado y su puntaje de similitud.	**`id_resultado_rag`**
6	**Evaluación (`Evaluaciones`)**	Núcleo	Métricas cuantitativas de calidad de la respuesta RAG generada (**`faithfulness`**, **`answer_relevancy`**, **`context_recall`**).	**`id_eval`**
7	**Departamento**	Dominio	Unidad organizacional o facultad científica a la que están adscritos los investigadores del centro.	**`id_departamento`**
8	**Proyecto_Investigacion**	Dominio	Marco investigativo formal con título, fecha de inicio y estado, liderado por un investigador principal.	**`id_proyecto_investigacion`**
9	**Experimento**	Dominio	Ejecución práctica de laboratorio realizada en una fecha bajo un proyecto, un investigador y un protocolo.	**`id_experimento`**
10	**Condicion_Ambiental**	Dominio	Registro climático (temperatura, humedad y presión atmosférica) medido durante la sesión experimental.	**`id_condicion_ambiental`**
11	**Desecho**	Dominio	Residuo químico o biológico derivado de un experimento que requiere control de disposición ambiental.	**`id_desecho`**
12	**Muestra**	Dominio	Espécimen físico, químico o biológico recolectado y analizado dentro de un experimento.	**`id_muestra`**
13	**Resultado_Estructurado**	Dominio	Medición analítica tabular (métrica, valor numérico y unidad de medida) obtenida de una muestra.	**`id_resultado`**
14	**Reactivo**	Dominio	Catálogo maestro de compuestos químicos definidos por su nombre científico, número CAS y nivel de peligro.	**`id_reactivo`**
15	**Lote_Reactivo**	Dominio	Existencia física de un reactivo en el almacén con cantidad disponible, fecha de caducidad y ubicación.	**`id_lote_reactivo`**
16	**Consumo_Lote_Reactivo**	Intermedia	Tabla asociativa que registra la cantidad exacta extraída de un lote de reactivo durante un experimento.	**`id_consumo_lote_reactivo`**
17	**Equipo_Laboratorio**	Dominio	Maquinaria o instrumento científico disponible en el laboratorio (nombre y modelo).	**`id_equipo`**
18	**Registro_Uso_Equipo**	Intermedia	Bitácora asociativa que audita qué investigador operó qué equipo, en qué fecha y a qué hora.	**`id_registro`**
19	**Mantenimiento_Equipo**	Dominio	Historial de intervenciones preventivas, calibraciones o reparaciones realizadas a un equipo.	**`id_mantenimiento`**
20	**Embeddings_Texto / Embeddings_Imagen / Query_Embeddings**	Vectorial	Tablas especializadas que almacenan los *chunks* textuales y los vectores densos en **`pgvector`** (384d y 512d).	**`id_embedding`**

2.2 Relaciones y cardinalidades

Relación	Entidad A	Entidad B	Cardinalidad	Participación (A / B)	Regla de negocio que la justifica
realiza	**`Investigador`** (Usuario)	**`Consultas`**	1:N	Parcial / Total	Un investigador puede formular muchas consultas al asistente RAG; toda consulta debe tener un autor registrado.
contiene	**`Protocolo_Estandar`** (Documento)	**`Imagenes`**	1:N	Parcial / Total	Un protocolo estándar puede contener varias figuras técnicas; toda imagen está vinculada a un documento de referencia.
captura	**`Muestra`**	**`Imagenes`**	1:N	Parcial / Parcial	Una muestra experimental puede contar con varias fotografías microscópicas; las figuras teóricas de manual no provienen de una muestra.
recupera	**`Consultas`**	**`Protocolo_Estandar`** / **`Imagenes`**	N:M (vía **`Resultados`**)	Total en **`Resultados`**	Una consulta recupera múltiples documentos o imágenes relevantes, y un mismo recurso puede ser recuperado por distintas consultas.
se evalúa	**`Consultas`**	**`Evaluaciones`**	1:1	Parcial / Total	Cada consulta procesada por el flujo RAG recibe un único registro consolidado de evaluación de calidad.
agrupa	**`Departamento`**	**`Investigador`**	1:N	Parcial / Total	Un departamento integra a múltiples investigadores, pero cada investigador está adscrito a un único departamento.
lidera	**`Investigador`**	**`Proyecto_Investigacion`**	1:N	Parcial / Total	Un investigador principal puede dirigir varios proyectos; todo proyecto requiere obligatoriamente un investigador líder.
enmarca	**`Proyecto_Investigacion`**	**`Experimento`**	1:N	Parcial / Total	Un proyecto comprende múltiples ensayos experimentales; todo experimento se ejecuta dentro de un proyecto formal.
ejecuta	**`Investigador`**	**`Experimento`**	1:N	Parcial / Total	Un investigador lleva a cabo múltiples experimentos; cada experimento tiene un único investigador responsable de su ejecución.
rige	**`Protocolo_Estandar`**	**`Experimento`**	1:N	Parcial / Total	Un protocolo estándar guía la ejecución de muchos experimentos; cada experimento sigue un protocolo definido.
registra clima	**`Experimento`**	**`Condicion_Ambiental`**	1:1	Total / Total	Cada sesión experimental registra un único reporte consolidado de temperatura, humedad y presión ambiental del recinto.
genera residuo	**`Experimento`**	**`Desecho`**	1:N	Parcial / Total	Un experimento puede producir varios tipos de desechos regulados; cada registro de desecho proviene de un experimento.

Relación	Entidad A	Entidad B	Cardinalidad	Participación (A / B)	Regla de negocio que la justifica
produce	`Experimento`	`Muestra`	1:N	Parcial / Total	Un experimento genera una o múltiples muestras físicas; toda muestra proviene de un experimento específico.
arroja	`Muestra`	`Resultado_Estructurado`	1:N	Parcial / Total	A una misma muestra física se le miden múltiples métricas numéricas (ej. pH, absorbancia, concentración).
cataloga	`Reactivo`	`Lote_Reactivo`	1:N	Parcial / Total	Un compuesto químico del catálogo puede almacenarse en múltiples lotes físicos con distinta caducidad y ubicación.
consume	`Experimento`	`Lote_Reactivo`	N:M (vía `Consumo_Lote_Reactivo`)	Parcial / Parcial	Un experimento consume fracciones de varios lotes químicos, y un lote abastece a múltiples experimentos hasta agotarse.
opera	`Investigador`	`Equipo_Laboratorio`	N:M (vía `Registro_Uso_Equipo`)	Parcial / Parcial	Los investigadores utilizan diversos equipos del laboratorio, y cada equipo es operado por múltiples investigadores en distintos turnos.
recibe	`Equipo_Laboratorio`	`Mantenimiento_Equipo`	1:N	Parcial / Total	Un equipo de laboratorio recibe múltiples mantenimientos preventivos o correctivos a lo largo de su vida útil.

3. DISEÑO LÓGICO EN 3FN

3.1 Esquema relacional

A continuación se presenta una fila por cada tabla del esquema híbrido. La clave primaria (**PK**) aparece subrayada y cada clave foránea (**FK**) indica explícitamente la tabla a la que referencia:

Tabla	PK (subrayada)	FK (→ tabla referenciada)	Atributos	Restricciones relevantes (UNIQUE, CHECK, NOT NULL)
Departamento	`id_departamento`	—	`nombre`	`nombre UNIQUE NOT NULL`
Investigador *(Usuarios)*	`id_investigador`	`id_departamento` → `Departamento`	`nombre, email, rol`	`email UNIQUE NOT NULL`; `rol CHECK (IN 'admin', 'investigador', 'analista', 'tecnico')`
Proyecto_Investigacion	`id_proyecto_investigacion`	`id_investigador_principal` → `Investigador`	`titulo, fecha_inicio, estado`	`titulo, fecha_inicio NOT NULL`; `estado CHECK (IN 'activo', 'pausado', 'finalizado')`
Protocolo_Estandar *(Documentos)*	`id_protocolo`	—	`nombre, version, idioma, fecha, fuente, texto`	`UNIQUE(nombre, version)`; `idioma CHECK (IN 'es', 'en')`; `texto NOT NULL`

Experimento	`id_experimento`	`id_proyecto` → `Proyecto_Investigacion`
		`id_investigador` → `Investigador`
		`id_protocolo` → `Protocolo_Estandar`
			`fecha_ejecucion`	`fecha_ejecucion NOT NULL`; todas las FK `NOT NULL`

Condicion_Ambiental	`id_condicion_ambiental`	`id_experimento` → `Experimento`	`temperatura, humedad, presion`	`id_experimento UNIQUE NOT NULL` (1:1); `humedad CHECK (BETWEEN 0 AND 100)`; `presion CHECK (> 0)`
Desecho	`id_desecho`	`id_experimento` → `Experimento`	`tipo_residuo, cantidad_residuo`	`tipo_residuo NOT NULL`; `cantidad_residuo CHECK (> 0)`
Muestra	`id_muestra`	`id_experimento` → `Experimento`	`tipo_muestra`	`tipo_muestra NOT NULL`; `id_experimento NOT NULL`
Resultado_Estructurado	`id_resultado`	`id_muestra` → `Muestra`	`metrica, valor_numerico, unidad`	`metrica, valor_numerico, unidad NOT NULL`
Reactivo	`id_reactivo`	—	`nombre_cientifico, cas_numero, nivel_peligro`	`cas_numero UNIQUE NOT NULL`; `nivel_peligro CHECK (BETWEEN 1 AND 5)`
Lote_Reactivo	`id_lote_reactivo`	`reactivo_id` → `Reactivo`	`cantidad, caducidad, ubicacion`	`cantidad CHECK (>= 0)`; `caducidad, ubicacion NOT NULL`
Consumo_Lote_Reactivo	`id_consumo_lote_reactivo`	`id_lote_reactivo` → `Lote_Reactivo` `id_experimento` → `Experimento`	`cantidad_usada`	`cantidad_usada CHECK (> 0)`; `UNIQUE(id_lote_reactivo, id_experimento)`
Equipo_Laboratorio	`id_equipo`	—	`nombre, modelo`	`nombre NOT NULL`; `modelo NOT NULL`
Registro_Uso_Equipo	`id_registro`	`id_equipo` → `Equipo_Laboratorio` `id_investigador` → `Investigador`	`fecha, hora_de_uso`	`fecha NOT NULL`; `hora_de_uso NOT NULL`
Mantenimiento_Equipo	`id_mantenimiento`	`id_equipo` → `Equipo_Laboratorio`	`fecha`	`fecha NOT NULL`; `id_equipo NOT NULL`

Tabla	PK (subrayada)	FK (→ tabla referenciada)	Atributos	Restricciones relevantes (UNIQUE, CHECK, NOT NULL)
Imagenes	`id_img`	`id_protocolo` → `Protocolo_Estandar` `id_muestra` → `Muestra` *(opcional)*	`ruta_archivo`, `descripcion`	`ruta_archivo UNIQUE NOT NULL`; `descripcion NOT NULL`
Consultas	`id_consulta`	`id_investigador` → `Investigador`	`texto_pregunta`, `fecha`	`texto_pregunta NOT NULL`; `fecha NOT NULL`

Resultados *(RAG)*	`id_resultado_rag`	`id_consulta` → `Consultas`
		`id_protocolo` → `Protocolo_Estandar`
		`id_img` → `Imagenes`
			`score_similitud`	`CHECK`: exactamente uno de `id_protocolo` / `id_img` no nulo (XOR); `score_similitud BETWEEN -1 AND 1`

Evaluaciones	`id_eval`	`id_consulta` → `Consultas`	`faithfulness`, `answer_relevancy`, `context_recall`, `modelo_eval`, `fecha`	`id_consulta UNIQUE NOT NULL` (1:1); métricas `CHECK (BETWEEN 0 AND 1)`
Embeddings_Texto	`id_embedding`	`id_protocolo` → `Protocolo_Estandar`	`chunk_id`, `estrategia_chunking`, `chunk_texto`, `vector_embedding`, `modelo`	`UNIQUE(id_protocolo, estrategia_chunking, chunk_id)`; `VECTOR(384) NOT NULL`
Embeddings_Imagen	`id_embedding`	`id_img` → `Imagenes`	`vector_embedding`, `modelo`	`VECTOR(512) NOT NULL`; `modelo NOT NULL`
Query_Embeddings	`id_query_embedding`	`id_consulta` → `Consultas`	`vector_texto`, `vector_clip_texto`, `modelo`	`VECTOR(384)` y `VECTOR(512)`; `modelo NOT NULL`

3.2 Justificación de la normalización

- **Primera Forma Normal (1FN):** Se garantiza que todos los atributos de las tablas del esquema son estrictamente atómicos y no existen columnas multivaluadas, listas separadas por comas ni grupos repetitivos (como `metrica_1, metrica_2, metrica_3` o `reactivo_1, reactivo_2`). En particular, las múltiples mediciones analíticas obtenidas de una muestra física se desacoplaron en filas atómicas dentro de la entidad `Resultado_Estructurado`, y el consumo de múltiples reactivos por experimento se normalizó mediante la tabla asociativa `Consumo_Lote_Reactivo`.
- **Segunda Forma Normal (2FN):** Todas las tablas cumplen 1FN y, en aquellas con clave candidata o clave compuesta, todo atributo no clave depende funcionalmente de la clave completa y nunca de una parte de ella:
  - En `Consumo_Lote_Reactivo` (con clave candidata compuesta `UNIQUE(id_lote_reactivo, id_experimento)`), el atributo `cantidad_usada` depende conjuntamente del lote extraído y del experimento que lo consumió; los atributos exclusivos del lote (`caducidad`, `ubicacion`) permanecen en `Lote_Reactivo`.
  - En `Embeddings_Texto` (con clave candidata compuesta `(id_protocolo, estrategia_chunking, chunk_id)`), tanto `chunk_texto` como `vector_embedding` dependen de la combinación completa de documento, estrategia de partición y número de fragmento.
- **Tercera Forma Normal (3FN):** El esquema se encuentra en 2FN y se eliminaron todas las dependencias transitivas entre atributos no clave:
  - *Dependencia transitiva eliminada en inventario químico:* Inicialmente, si en `Lote_Reactivo` se guardaran los atributos `nombre_cientifico`, `cas_numero` y `nivel_peligro`, existiría la dependencia transitiva `id_lote_reactivo → cas_numero → (nombre_cientifico, nivel_peligro)`, generando redundancia y anomalías de actualización cada vez que se adquiere un nuevo frasco del mismo reactivo. Se eliminó creando la tabla maestra `Reactivo` y referenciándola mediante `reactivo_id`.
  - *Dependencia transitiva eliminada en personal:* El nombre del departamento se desacopló de `Investigador` hacia la entidad `Departamento`, eliminando la cadena transitiva `id_investigador → id_departamento → nombre_departamento`.

3.3 Decisiones de diseño

- **Arco exclusivo en `Resultados` mediante dos FK opcionales:** Se decidió que la tabla `Resultados` utilice dos claves foráneas anulables (`id_protocolo` e `id_img`) gobernadas por la restricción `CHECK ((id_protocolo IS NOT NULL AND id_img IS NULL) OR (id_protocolo IS NULL AND id_img IS NOT NULL))` en lugar de crear dos tablas de resultados separadas. Esto permite consolidar en una sola tabla y bajo un mismo ranking de `score_similitud` los resultados multimodales (tanto protocolos textuales como capturas microscópicas) recuperados para una misma `id_consulta`.
- **Integración nativa del núcleo RAG con el dominio LIMS:** En lugar de duplicar tablas de usuarios y documentos desconectadas del negocio, `Investigador` asume directamente el rol de la entidad `Usuarios` del núcleo RAG y `Protocolo_Estandar` asume el rol de `Documentos`, permitiendo cruzar en una sola consulta híbrida los *embeddings* de un manual con los experimentos reales que lo ejecutaron.

- **Distinción entre `Resultado_Estructurado` y `Resultados`:** Se mantuvieron como tablas independientes porque representan conceptos ortogonales: `Resultado_Estructurado` almacena mediciones fisicoquímicas de laboratorio sobre una muestra física (ej. `pH = 7.35`), mientras que `Resultados` registra los documentos o imágenes recuperados por similitud vectorial ante una pregunta en lenguaje natural.
- **Atributos con restricciones de dominio frente a tablas catálogo menores:** Atributos de conjunto cerrado e invariable como `idioma` (`'es'`, `'en'`), `rol` y `estado` se modelaron como columnas `VARCHAR` con restricción `CHECK` para evitar *joins* innecesarios, mientras que conceptos organizacionales como `Departamento` se diseñaron como tablas catálogo independientes.

4. IDENTIFICACIÓN DE CAMPOS VECTORIZABLES

Campo origen	Tabla origen	Modalidad	Modelo de embedding	Dim.	Tabla destino	Justificación
`texto` (por *chunk*)	**`Protocolo_Estandar`** (Documentos)	Texto	**`sentence-transformers/all-MiniLM-L6-v2`**	384	**`Embeddings_Texto`**	Los protocolos de laboratorio son extensos; vectorizarlos por fragmentos permite recuperar el paso operativo o advertencia exacta sin truncar el contexto.
`nombre` (título)	**`Protocolo_Estandar`** (Documentos)	Texto	**`sentence-transformers/all-MiniLM-L6-v2`**	384	**`Embeddings_Texto`**	Incluir el título del protocolo en el encabezado semántico del primer *chunk* mejora la precisión cuando el investigador pregunta por una técnica específica.
`texto_pregunta` (búsqueda documental)	**`Consultas`**	Texto	**`sentence-transformers/all-MiniLM-L6-v2`**	384	**`Query_Embeddings`**	Proyecta la pregunta del investigador en el espacio de 384 dimensiones para compararla directamente contra los fragmentos de **`Embeddings_Texto`**.
`texto_pregunta` (búsqueda visual)	**`Consultas`**	Texto (Multimodal)	**`openai/clip-vit-base-patch32`** (Text Encoder)	512	**`Query_Embeddings`**	Proyecta la descripción textual en el espacio compartido de 512 dimensiones de CLIP para recuperar fotografías en **`Embeddings_Imagen`**.
Archivo de imagen (matriz de píxeles)	**`Imagenes`**	Imagen	**`openai/clip-vit-base-patch32`** (Vision Encoder)	512	**`Embeddings_Imagen`**	Codifica patrones visuales reales (morfología celular, coloración, precipitados) abriendo el archivo físico con **`PIL.Image.open()`**.
`descripcion`	**`Imagenes`**	Texto	**`all-MiniLM-L6-v2`** / **`CLIP Text`**	384 / 512	**`Embeddings_Texto`**	Permite apoyo semántico adicional sobre las anotaciones descriptivas y observaciones técnicas de cada fotografía microscópica.

Procesamiento del contenido visual (PIL + CLIP): El *embedding* almacenado en **`Embeddings_Imagen`** se calcula exclusivamente cargando en memoria los píxeles del archivo referenciado por **`ruta_archivo`** mediante la librería **`Pillow`** (**`PIL.Image.open(ruta)`**) y pasándolos por el preprocesador y codificador visual **`CLIPModel.get_image_features()`**. En ningún caso se vectoriza la cadena de texto de la ruta del archivo.

Búsqueda texto → imagen (Alineación en el espacio latente de 512 dimensiones): Cuando un investigador realiza una búsqueda de imágenes a partir de una descripción en texto libre (RF-03), no es posible usar el vector de **`all-MiniLM-L6-v2`** porque tiene 384 dimensiones y fue entrenado únicamente con corpus textuales. En su lugar, la consulta de texto se procesa con el **codificador de texto (Text Encoder) de CLIP ViT-B/32** (**`CLIPModel.get_text_features()`**), el cual genera un vector de **512 dimensiones** alineado mediante aprendizaje contrastivo en el mismo espacio vectorial hiperesférico que el **codificador de visión (Vision Encoder) de CLIP** (512 dimensiones). Así, PostgreSQL ejecuta la comparación directa **`embeddings_imagen.vector_embedding <=> query_embeddings.vector_clip_texto`**.

5. ESQUEMA SQL (TABLAS RELACIONALES Y VECTORIALES)

Archivo en el repositorio: **`sql/schema.sql`** (Script DDL completo y ejecutable sin errores sobre una base de datos PostgreSQL vacía con la extensión **`pgvector`**):

```
-- ================================================================================
-- UNIVERSIDAD DE CALDAS - BASES DE DATOS RELACIONALES
-- ENTREGA 1: SISTEMA HÍBRIDO RELACIONAL-VECTORIAL LIMS + RAG
-- Autores: Estupiñán, Noreña, Puerta
-- Archivo: sql/schema.sql
-- ================================================================================

CREATE EXTENSION IF NOT EXISTS vector;

-- ================================================================================
-- 1. MÓDULO DE ORGANIZACIÓN, PERSONAL Y NÚCLEO RAG (USUARIOS)
-- ================================================================================
CREATE TABLE departamento (
    id_departamento SERIAL PRIMARY KEY,
    nombre VARCHAR(120) NOT NULL UNIQUE
);

CREATE TABLE investigador (
    id_investigador SERIAL PRIMARY KEY,
    nombre VARCHAR(150) NOT NULL,
    email VARCHAR(150) NOT NULL UNIQUE,
    rol VARCHAR(30) NOT NULL DEFAULT 'investigador'
        CHECK (rol IN ('admin', 'investigador', 'analista', 'tecnico')),
    id_departamento INT NOT NULL
        REFERENCES departamento(id_departamento) ON DELETE RESTRICT
);

CREATE TABLE proyecto_investigacion (
    id_proyecto_investigacion SERIAL PRIMARY KEY,
    titulo VARCHAR(250) NOT NULL,
    fecha_inicio DATE NOT NULL,
    estado VARCHAR(30) NOT NULL DEFAULT 'activo'
        CHECK (estado IN ('activo', 'pausado', 'finalizado')),
    id_investigador_principal INT NOT NULL
        REFERENCES investigador(id_investigador) ON DELETE RESTRICT
);

-- ================================================================================
-- 2. MÓDULO DOCUMENTAL (PROTOCOLOS / DOCUMENTOS) Y EJECUCIÓN EXPERIMENTAL
-- ================================================================================
CREATE TABLE protocolo_estandar (
    id_protocolo SERIAL PRIMARY KEY,
    nombre VARCHAR(200) NOT NULL,
    version VARCHAR(20) NOT NULL DEFAULT '1.0',
    idioma VARCHAR(5) NOT NULL DEFAULT 'es'
        CHECK (idioma IN ('es', 'en')),
    fecha DATE NOT NULL DEFAULT CURRENT_DATE,
    fuente VARCHAR(150) NOT NULL DEFAULT 'Laboratorio Interno',
    texto TEXT NOT NULL,
    UNIQUE (nombre, version)
);

CREATE TABLE experimento (
    id_experimento SERIAL PRIMARY KEY,
    fecha_ejecucion TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
    id_proyecto INT NOT NULL
        REFERENCES proyecto_investigacion(id_proyecto_investigacion) ON DELETE RESTRICT,
    id_investigador INT NOT NULL
        REFERENCES investigador(id_investigador) ON DELETE RESTRICT,
    id_protocolo INT NOT NULL
        REFERENCES protocolo_estandar(id_protocolo) ON DELETE RESTRICT
);

CREATE TABLE condicion_ambiental (
    id_condicion_ambiental SERIAL PRIMARY KEY,
    temperatura NUMERIC(5,2) NOT NULL,
    humedad NUMERIC(5,2) NOT NULL CHECK (humedad BETWEEN 0 AND 100),
    presion NUMERIC(7,2) NOT NULL CHECK (presion > 0),
    id_experimento INT NOT NULL UNIQUE
        REFERENCES experimento(id_experimento) ON DELETE CASCADE
);

CREATE TABLE desecho (
    id_desecho SERIAL PRIMARY KEY,
    tipo_residuo VARCHAR(100) NOT NULL,
    cantidad_residuo NUMERIC(10,3) NOT NULL CHECK (cantidad_residuo > 0),
    id_experimento INT NOT NULL
        REFERENCES experimento(id_experimento) ON DELETE CASCADE
);

-- ================================================================================
```

```
-- 3. MÓDULO DE MUESTRAS Y RESULTADOS ESTRUCTURADOS DE LABORATORIO
-- ============================================================================
CREATE TABLE muestra (
    id_muestra SERIAL PRIMARY KEY,
    tipo_muestra VARCHAR(100) NOT NULL,
    id_experimento INT NOT NULL
        REFERENCES experimento(id_experimento) ON DELETE CASCADE
);

CREATE TABLE resultado_estructurado (
    id_resultado SERIAL PRIMARY KEY,
    metrica VARCHAR(100) NOT NULL,
    valor_numerico NUMERIC(14,4) NOT NULL,
    unidad VARCHAR(30) NOT NULL,
    id_muestra INT NOT NULL
        REFERENCES muestra(id_muestra) ON DELETE CASCADE
);

-- ============================================================================
-- 4. MÓDULO DE INVENTARIO QUÍMICO Y TRAZABILIDAD DE LOTES
-- ============================================================================
CREATE TABLE reactivo (
    id_reactivo SERIAL PRIMARY KEY,
    nombre_cientifico VARCHAR(180) NOT NULL,
    cas_numero VARCHAR(30) NOT NULL UNIQUE,
    nivel_peligro INT NOT NULL CHECK (nivel_peligro BETWEEN 1 AND 5)
);

CREATE TABLE lote_reactivo (
    id_lote_reactivo SERIAL PRIMARY KEY,
    cantidad NUMERIC(12,3) NOT NULL CHECK (cantidad >= 0),
    caducidad DATE NOT NULL,
    ubicacion VARCHAR(120) NOT NULL,
    reactivo_id INT NOT NULL
        REFERENCES reactivo(id_reactivo) ON DELETE RESTRICT
);

CREATE TABLE consumo_lote_reactivo (
    id_consumo_lote_reactivo SERIAL PRIMARY KEY,
    id_lote_reactivo INT NOT NULL
        REFERENCES lote_reactivo(id_lote_reactivo) ON DELETE RESTRICT,
    id_experimento INT NOT NULL
        REFERENCES experimento(id_experimento) ON DELETE CASCADE,
    cantidad_usada NUMERIC(12,3) NOT NULL CHECK (cantidad_usada > 0),
    UNIQUE (id_lote_reactivo, id_experimento)
);

-- ============================================================================
-- 5. MÓDULO DE EQUIPAMIENTO Y MANTENIMIENTO
-- ============================================================================
CREATE TABLE equipo_laboratorio (
    id_equipo SERIAL PRIMARY KEY,
    nombre VARCHAR(150) NOT NULL,
    modelo VARCHAR(100) NOT NULL
);

CREATE TABLE registro_uso_equipo (
    id_registro SERIAL PRIMARY KEY,
    fecha DATE NOT NULL DEFAULT CURRENT_DATE,
    hora_de_uso TIME NOT NULL,
    id_equipo INT NOT NULL
        REFERENCES equipo_laboratorio(id_equipo) ON DELETE RESTRICT,
    id_investigador INT NOT NULL
        REFERENCES investigador(id_investigador) ON DELETE RESTRICT
);

CREATE TABLE mantenimiento_equipo (
    id_mantenimiento SERIAL PRIMARY KEY,
    fecha DATE NOT NULL,
    id_equipo INT NOT NULL
        REFERENCES equipo_laboratorio(id_equipo) ON DELETE CASCADE
);

-- ============================================================================
-- 6. MÓDULO MULTIMODAL DE IMÁGENES
-- ============================================================================
CREATE TABLE imagenes (
    id_img SERIAL PRIMARY KEY,
    id_protocolo INT NOT NULL
        REFERENCES protocolo_estandar(id_protocolo) ON DELETE CASCADE,
    id_muestra INT
        REFERENCES muestra(id_muestra) ON DELETE SET NULL,
    ruta_archivo VARCHAR(500) NOT NULL UNIQUE,
    descripcion TEXT NOT NULL
);

-- ============================================================================
-- 7. MÓDULO DE CONSULTAS RAG, RESULTADOS Y EVALUACIÓN DE CALIDAD
-- ============================================================================
CREATE TABLE consultas (
```

```
    id_consulta SERIAL PRIMARY KEY,
    id_investigador INT NOT NULL
        REFERENCES investigador(id_investigador) ON DELETE CASCADE,
    texto_pregunta TEXT NOT NULL,
    fecha TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP
);

CREATE TABLE resultados (
    id_resultado_rag SERIAL PRIMARY KEY,
    id_consulta INT NOT NULL
        REFERENCES consultas(id_consulta) ON DELETE CASCADE,
    id_protocolo INT
        REFERENCES protocolo_estandar(id_protocolo) ON DELETE CASCADE,
    id_img INT
        REFERENCES imagenes(id_img) ON DELETE CASCADE,
    score_similitud NUMERIC(6,5) NOT NULL
        CHECK (score_similitud BETWEEN -1 AND 1),
    CHECK (
        (id_protocolo IS NOT NULL AND id_img IS NULL) OR
        (id_protocolo IS NULL AND id_img IS NOT NULL)
    )
);

CREATE TABLE evaluaciones (
    id_eval SERIAL PRIMARY KEY,
    id_consulta INT NOT NULL UNIQUE
        REFERENCES consultas(id_consulta) ON DELETE CASCADE,
    faithfulness NUMERIC(4,3) NOT NULL CHECK (faithfulness BETWEEN 0 AND 1),
    answer_relevancy NUMERIC(4,3) NOT NULL CHECK (answer_relevancy BETWEEN 0 AND 1),
    context_recall NUMERIC(4,3) NOT NULL CHECK (context_recall BETWEEN 0 AND 1),
    modelo_eval VARCHAR(100) NOT NULL,
    fecha TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP
);

-- ============================================================================
-- 8. TABLAS VECTORIALES E ÍNDICES HNSW (PGVECTOR)
-- ============================================================================
CREATE TABLE embeddings_texto (
    id_embedding SERIAL PRIMARY KEY,
    id_protocolo INT NOT NULL
        REFERENCES protocolo_estandar(id_protocolo) ON DELETE CASCADE,
    chunk_id INT NOT NULL,
    estrategia_chunking VARCHAR(20) NOT NULL
        CHECK (estrategia_chunking IN ('fixed-size', 'sentence-aware', 'semantic')),
    chunk_texto TEXT NOT NULL,
    vector_embedding VECTOR(384) NOT NULL,
    modelo VARCHAR(100) NOT NULL DEFAULT 'all-MiniLM-L6-v2',
    UNIQUE (id_protocolo, estrategia_chunking, chunk_id)
);

CREATE TABLE embeddings_imagen (
    id_embedding SERIAL PRIMARY KEY,
    id_img INT NOT NULL
        REFERENCES imagenes(id_img) ON DELETE CASCADE,
    vector_embedding VECTOR(512) NOT NULL,
    modelo VARCHAR(100) NOT NULL DEFAULT 'clip-vit-base-patch32'
);

CREATE TABLE query_embeddings (
    id_query_embedding SERIAL PRIMARY KEY,
    id_consulta INT NOT NULL
        REFERENCES consultas(id_consulta) ON DELETE CASCADE,
    vector_texto VECTOR(384),
    vector_clip_texto VECTOR(512),
    modelo VARCHAR(100) NOT NULL
);

-- Índices vectoriales HNSW para búsqueda rápida por similitud de coseno
CREATE INDEX idx_hnsw_embeddings_texto
    ON embeddings_texto USING hnsw (vector_embedding vector_cosine_ops);

CREATE INDEX idx_hnsw_embeddings_imagen
    ON embeddings_imagen USING hnsw (vector_embedding vector_cosine_ops);
```

6. PLAN DE EXPERIMENTO DE CHUNKING

6.1 Estrategias y parámetros

Estrategia	Parámetros sugeridos	Parámetros del grupo	Herramienta / librería	Por qué podría funcionar en su dominio
Fixed-size	`chunk_size = 256` tokens, `overlap = 32`	`chunk_size = 256` tokens, `overlap = 40` tokens	`langchain` (`TokenTextSplitter`)	Garantiza bloques uniformes que respetan el límite de ventana de `all-MiniLM-L6-v2` (256 tokens efectivos) y un solapamiento ligeramente mayor (40 tokens) evita cortar nombres compuestos de reactivos o números CAS.
Sentence-aware	máx. 5 oraciones, `overlap = 1` oración	máx. 5 oraciones, `overlap = 1` oración	`spaCy` (`es_core_news_sm` / `en_core_web_sm`) + lógica propia en Python	Los protocolos estándar de laboratorio están escritos como secuencias de pasos imperativos; respetar los límites de oración impide dejar una instrucción de dosificación o temperatura truncada a mitad de frase.
Semantic	umbral coseno entre `0.75` y `0.85`	umbral de similitud coseno `0.80` entre oraciones adyacentes	`semantic-chunkers` / implementación propia con `all-MiniLM-L6-v2`	Los SOPs de laboratorio se estructuran en secciones semánticamente muy diferenciadas (*1. Equipos y Reactivos, 2. Condiciones Ambientales, 3. Procedimiento, 4. Gestión de Desechos*); el salto de vocabulario técnico permite agrupar cada fase completa en un solo *chunk*.

Hipótesis: En el dominio de protocolos científicos de laboratorio (LIMS), esperamos que la estrategia **Semantic** (seguida por **Sentence-aware**) obtenga las métricas más altas en `context_recall` y `faithfulness`. Esto se debe a que en un procedimiento químico las advertencias de bioseguridad, las condiciones de temperatura/presión y las proporciones del reactivo forman una unidad lógica indivisible dentro de cada etapa experimental; mientras que `Fixed-size` puede partir un paso crítico en dos fragmentos distintos e inducir respuestas incompletas en el generador RAG, el corte semántico con umbral `0.80` preserva cada etapa operativa completa.